



Facultad de
**Ciencias Sociales y
Tecnologías de la Inf.**
Talavera de la Reina. UCLM

UNIVERSIDAD DE CASTILLA-LA MANCHA
Tecnologías y Sistemas de Información

GRADO EN INGENIERÍA INFORMÁTICA
SISTEMAS DE INFORMACIÓN

Trabajo Fin de Grado

**Creación de una Plataforma/API para la
Evaluación de Calidad de Datos
en Proyectos de IA**

Autoría: Alejandro Manuel Saiz García

Tutoría: Fernando Gualo Cejudo y Ricardo Pérez del Castillo

Junio, 2026

Alejandro Manuel Saiz García

Talavera de la Reina – España

© 2026 Alejandro Manuel Saiz García

Permission is granted to copy, distribute and/or modify this document under the terms of the GNU Free Documentation License, Version 1.3 or any later version published by the Free Software Foundation; with no Invariant Sections, no Front-Cover Texts, and no Back-Cover Texts. A copy of the license is included in the section entitled "GNU Free Documentation License".

Se permite la copia, distribución y/o modificación de este documento bajo los términos de la Licencia de Documentación Libre GNU, versión 1.3 o cualquier versión posterior publicada por la *Free Software Foundation*; sin secciones invariantes. Una copia de esta licencia esta incluida en el apéndice titulado «GNU Free Documentation License».

Muchos de los nombres usados por las compañías para diferenciar sus productos y servicios son reclamados como marcas registradas. Allí donde estos nombres aparezcan en este documento, y cuando la persona autora haya sido informada de esas marcas registradas, los nombres estarán escritos en mayúsculas o como nombres propios.

TRIBUNAL:

Presidencia:

Vocal:

Secretaría:

FECHA DE DEFENSA:

CALIFICACIÓN:

PRESIDENCIA

VOCAL

SECRETARÍA

Fdo.:

Fdo.:

Fdo.:

Resumen

La calidad de los datos constituye un factor determinante en el éxito de los proyectos de inteligencia artificial y aprendizaje automático. Sin embargo, las herramientas disponibles para su evaluación presentan limitaciones significativas: las bibliotecas basadas en código imponen una barrera técnica elevada, mientras que los *scripts* ad hoc carecen de estandarización, historización y mecanismos de decisión automatizados.

Este Trabajo Fin de Grado presenta DATAQUAL, una plataforma web *full-stack* para la evaluación automatizada de la calidad de datos. La plataforma implementa siete métricas de calidad alineadas con los estándares ISO/IEC 25012 e ISO/IEC 5259, un motor modular y extensible, un sistema de *fingerprinting* SHA-256 para la trazabilidad de incidencias entre evaluaciones y *Quality Gates* configurables inspirados en SonarQube. El sistema se despliega como ocho servicios Docker orquestados con Docker Compose, combinando una interfaz web interactiva (Next.js, React) con una API RESTful (Flask, Python) y procesamiento asíncrono (Celery, Redis).

La plataforma ha sido validada con conjuntos de datos ampliamente utilizados en el ámbito de la IA y la ciencia de datos, confirmando la detección efectiva de problemas de calidad, la trazabilidad de incidencias entre evaluaciones sucesivas y la correcta clasificación de datasets mediante *Quality Gates* con estados PASSED, WARNING y FAILED.

Abstract

Data quality is a determining factor in the success of artificial intelligence and machine learning projects. However, the tools available for its assessment have significant limitations: code-based libraries impose a high technical barrier, while ad hoc scripts lack standardisation, historisation and automated decision mechanisms.

This undergraduate thesis presents DATAQUAL, a full-stack web platform for automated data quality evaluation. The platform implements seven quality metrics aligned with the ISO/IEC 25012 and ISO/IEC 5259 standards, a modular and extensible engine, a SHA-256 fingerprinting system for issue traceability across evaluations, and configurable Quality Gates inspired by SonarQube. The system is deployed as eight Docker services orchestrated with Docker Compose, combining an interactive web interface (Next.js, React) with a RESTful API (Flask, Python) and asynchronous processing (Celery, Redis).

The platform has been validated with widely used datasets in the field of AI and data science, confirming the effective detection of quality issues, issue traceability across successive evaluations, and correct dataset classification through Quality Gates with PASSED, WARNING and FAILED states.

Agradecimientos

Aquí van mis agradecimientos. Lorem ipsum dolor sit amet, consectetur adipiscing elit, sed do eiusmod tempor incididunt ut labore et dolore magna aliqua.

(Esta sección está para completar)

Alejandro

Índice general

Resumen	III
Abstract	IV
Agradecimientos	V
Índice general	VI
Índice de cuadros	VIII
Índice de figuras	IX
Listado de acrónimos	X
1. Introducción	1
1.1. Motivación	1
1.2. Presentación de la solución	2
1.3. Justificación de la solución	3
1.4. Público objetivo	4
1.5. Alcance del proyecto	4
1.6. Estructura del documento	4
2. Antecedentes y estado del arte	6
2.1. Importancia de la calidad de datos en IA	6
2.1.1. Marcos conceptuales fundacionales	6
2.1.2. Impacto económico de la mala calidad de datos	6
2.1.3. El paradigma data-centric AI	7
2.2. Marco normativo: estándares ISO	8

ÍNDICE GENERAL

2.2.1.	ISO/IEC 25012: Modelo de calidad de datos	8
2.2.2.	ISO/IEC 5259: Calidad de datos para analítica e IA	8
2.2.3.	ISO/IEC 25024: Medición de la calidad de datos	10
2.3.	Alcance metodológico	10
2.3.1.	Taxonomía de características de calidad según ISO/IEC 5259-2 . .	10
2.3.2.	Características evaluables algorítmicamente	11
2.3.3.	Características fuera del alcance del proyecto	13
2.3.4.	Priorización de características para el MVP	14
2.4.	Estado del arte: herramientas existentes	15
2.4.1.	Great Expectations	15
2.4.2.	Apache Deequ	15
2.4.3.	DQOps	16
2.4.4.	Soda Core	16
2.4.5.	Otras herramientas relevantes	17
2.4.6.	Análisis comparativo	17
2.5.	Diferenciación de DATAQUAL	18
2.6.	Justificación académica	19
3.	Objetivos	21
3.1.	Objetivo general	21
3.2.	Objetivos específicos	21
3.2.1.	OE1. Módulo de ingesta y almacenamiento	21
3.2.2.	OE2. Motor de evaluación con métricas parametrizables	22
3.2.3.	OE3. API RESTful con especificación formal	23
3.2.4.	OE4. Aplicación web con <i>dashboards</i> interactivos	24
3.2.5.	OE5. Mecanismos de identificación de problemas	25
3.3.	Objetivos transversales	26
3.4.	Alcance y limitaciones	27
	Referencias	30

Índice de cuadros

2.1. Correspondencia entre las dimensiones de calidad de International Organization for Standardization (ISO)/IEC 25012 e ISO/IEC 5259-2 y las métricas implementadas en DATAQUAL	9
2.2. Cobertura de DATAQUAL respecto al modelo de calidad de ISO/IEC 5259-2	12
2.3. Comparativa de DATAQUAL con herramientas de calidad de datos existentes	18

Índice de figuras

Listado de acrónimos

API	Application Programming Interface
CRUD	Create, Read, Update, Delete
CSV	Comma-Separated Values
DMBOK	Data Management Body of Knowledge
EDA	Exploratory Data Analysis
IA	Inteligencia Artificial
IQR	Interquartile Range
ISO	International Organization for Standardization
JWT	JSON Web Token
ML	Machine Learning
MLOps	Machine Learning Operations
MVC	Model-View-Controller
MVP	Minimum Viable Product
ORM	Object-Relational Mapping
PBKDF2	Password-Based Key Derivation Function 2
PII	Personally Identifiable Information
REST	Representational State Transfer
RGPD	Reglamento General de Protección de Datos
SAAS	Software as a Service
SHA	Secure Hash Algorithm
SLA	Service Level Agreement
SODACL	Soda Checks Language
SQL	Structured Query Language
SQUARE	Systems and Software Quality Requirements and Evaluation
TFG	Trabajo Fin de Grado

LISTADO DE ACRÓNIMOS

UI	User Interface
UML	Unified Modeling Language
YAML	YAML Ain't Markup Language

Capítulo 1

Introducción

Un modelo de Inteligencia Artificial (IA) es, en última instancia, tan fiable como los datos con los que fue entrenado. Esta dependencia, evidente en teoría, tiene consecuencias prácticas graves y documentadas: sistemas que discriminan, predicciones que fallan en producción, auditorías imposibles de realizar porque nadie registró el estado de los datos en el momento del entrenamiento. El presente Trabajo Fin de Grado (TFG) responde a esta realidad con el diseño e implementación de DATAQUAL, una plataforma web para la evaluación automatizada de la calidad de datos en proyectos de IA.

Este capítulo introductorio presenta el problema que motiva el desarrollo de la plataforma, describe la solución propuesta y sus capacidades principales, justifica su necesidad frente a los enfoques existentes, identifica el público al que se dirige y describe la estructura del documento.

1.1 Motivación

El principio conocido como *garbage in, garbage out* lleva décadas resumiendo una verdad incómoda para la industria del dato: la calidad de las salidas de un sistema está limitada por la calidad de sus entradas. En IA y Machine Learning (ML), esta dependencia es especialmente directa porque los modelos aprenden patrones de los propios datos de entrenamiento (Wang and Strong, 1996); si esos datos contienen errores, sesgos o valores ausentes, el modelo los hereda y, con frecuencia, los amplifica (Redman, 1998).

Los estudios más citados sobre el tema confirman que los problemas de calidad de datos superan a los errores algorítmicos como causa de fallos en producción. Sambasivan et al. (2021), a partir de entrevistas con 53 profesionales de IA en múltiples organizaciones, identificaron el etiquetado incorrecto, los datos desactualizados y las muestras no representativas como las causas predominantes de fracaso en despliegues de ML. Ng (2021) demostró que mejorar la calidad del dataset de entrenamiento produce ganancias de precisión que ningún ajuste arquitectónico puede igualar cuando los datos son defectuosos.

El coste económico es proporcional: Redman (2001) estimó que corregir un error se vuelve entre diez y cien veces más caro conforme avanza por las etapas de un proyecto. Encuestas recientes al sector cifran en torno al 60–80 % el tiempo que los profesionales de datos dedican

a limpieza y preparación (Kaggle, 2022), tiempo que no se invierte en construir ni mejorar modelos.

La calidad de los datos no es, además, únicamente una cuestión técnica. Los datos desequilibrados o no representativos son una fuente frecuente de sesgo con consecuencias éticas y sociales: el algoritmo de selección de personal de Amazon, descartado en 2018 por discriminar sistemáticamente a las candidatas femeninas (Dastin, 2018), y los sistemas de reconocimiento facial con tasas de error desproporcionadas para personas de piel oscura documentados por Buolamwini y Gebru (2018) ilustran cómo las deficiencias en los datos de entrenamiento se trasladan al comportamiento del modelo. El marco regulatorio refuerza esta dimensión: el Reglamento Europeo de IA (Parlamento Europeo y Consejo de la Unión Europea, 2024) establece requisitos explícitos de calidad, trazabilidad y documentación de los datos en sistemas de alto riesgo, y el Reglamento General de Protección de Datos (RGPD) (Parlamento Europeo y Consejo de la Unión Europea, 2016) exige que los datos personales sean exactos y estén actualizados, convirtiendo la evaluación formal de la calidad en una obligación legal, no solo una buena práctica.

Este trabajo nace del interés personal del autor por el tratamiento y la gestión de los datos como disciplina, y de su voluntad de profundizar en el ámbito de la inteligencia artificial y la ciencia de datos, campos en los que la calidad del dato de entrada resulta, precisamente, el factor más determinante.

1.2 Presentación de la solución

DATAQUAL es una plataforma web *full-stack* para la evaluación automatizada de la calidad de datos en proyectos de IA, concebida para que cualquier equipo pueda auditar sus datos sin necesidad de escribir código. Unifica en un mismo entorno la carga de datos, la configuración de métricas, la ejecución de evaluaciones y la consulta de resultados, y expone además una Application Programming Interface (API) Representational State Transfer (REST)ful (Fielding, 2000) para integrarse con herramientas externas. El despliegue se realiza mediante ocho servicios Docker orquestados con Docker Compose, lo que permite ejecutar la plataforma completa en cualquier máquina con un único comando y sin depender de servicios en la nube. Sus capacidades principales son:

- **Carga de conjuntos de datos** en formato Comma-Separated Values (CSV), con almacenamiento seguro en MinIO y versionado gestionado mediante una jerarquía de versiones con etiquetas personalizables.
- **Perfilado exploratorio del dataset**: análisis estadístico automático por columna que incluye distribuciones, valores nulos, tipos de datos, estadísticos descriptivos e histogramas, para facilitar la comprensión del dato antes de configurar las métricas formales.

- **Configuración de métricas de calidad** adaptadas al tipo de proyecto, con parámetros y umbrales personalizables alineados con los estándares ISO/IEC 25012 (ISO/IEC, 2008), ISO/IEC 25024 (ISO/IEC, 2015) e ISO/IEC 5259 (ISO/IEC, 2024).
- **Ejecución asíncrona de evaluaciones**, que analiza los conjuntos de datos frente a las métricas configuradas sin bloquear la interfaz de usuario.
- **Visualización interactiva de resultados** mediante cuadros de mando que incluyen gráficos de evolución, tablas de métricas por columna, histogramas, diagramas de caja y matrices de correlación.
- **Seguimiento de la evolución de la calidad** a lo largo del tiempo, gracias a un sistema de *fingerprinting* que permite comparar automáticamente los resultados con líneas base anteriores.
- **Quality Gates** (puertas de calidad): umbrales mínimos configurables que determinan si un conjunto de datos es apto para su uso, con estados PASSED, WARNING y FAILED, inspirados en el concepto homónimo de SonarQube (SonarSource, 2024).
- **Protección de datos sensibles**: el usuario marca las columnas que contienen información sensible al cargar el dataset, y la plataforma enmascara automáticamente sus valores en todos los resultados y muestras de la evaluación, evitando su exposición en los informes.
- **Interfaz multiidioma**: la plataforma soporta español e inglés, con cambio de idioma en tiempo real sin necesidad de recargar la aplicación.

1.3 Justificación de la solución

Evaluar la calidad de un dataset con *scripts* de Python o consultas Structured Query Language (SQL) ad hoc es viable para una exploración puntual, pero se vuelve insostenible cuando el número de proyectos crece o el equipo incorpora perfiles no técnicos. Cada equipo termina definiendo sus propias métricas con sus propios umbrales, sin posibilidad de comparar resultados entre proyectos ni de detectar si la calidad se degrada de una ejecución a la siguiente. DATAQUAL aborda ambas carencias con un catálogo de métricas alineado con ISO/IEC 25012 (ISO/IEC, 2008) e ISO/IEC 5259 (ISO/IEC, 2024) y un sistema de seguimiento entre ejecuciones basado en *fingerprinting*.

Herramientas más maduras como Great Expectations (Great Expectations, 2024) o Deequ de Amazon resuelven el problema de la estandarización, pero exigen que quien las configure sepa programar, lo que excluye a analistas y responsables de negocio. DATAQUAL invierte esta restricción: la interfaz web permite configurar y lanzar evaluaciones sin instalar nada ni escribir una línea de código, mientras que la API REST queda disponible para los perfiles técnicos que prefieran integrar las evaluaciones en sus propios flujos.

El tercer problema, compartido por todos los enfoques anteriores, es la ausencia de un veredicto claro: un *script* puede detectar que el 12 % de una columna es nulo, pero no indica si eso es aceptable para el proyecto concreto. DATAQUAL incorpora *Quality Gates* configurables (puntuación mínima, límite de issues críticos y límite de issues nuevos) que producen un estado PASSED, WARNING o FAILED, al modo en que SonarQube (SonarSource, 2024) lo hace para el código fuente.

1.4 Público objetivo

DATAQUAL está pensada para equipos multidisciplinares en los que conviven perfiles con distinto nivel técnico. Los ingenieros de datos pueden invocar las evaluaciones desde sus propios *scripts* o flujos mediante la API REST; los científicos de datos y los ingenieros de ML disponen de un mecanismo sistemático para verificar la calidad del dataset antes de arrancar el entrenamiento; y los analistas sin perfil técnico pueden explorar los resultados directamente desde el navegador sin instalar nada. Los responsables de calidad y cumplimiento normativo encuentran en los informes de evaluación evidencias auditables que facilitan la justificación ante los requisitos del RGPD (Parlamento Europeo y Consejo de la Unión Europea, 2016) y el Reglamento Europeo de IA (Parlamento Europeo y Consejo de la Unión Europea, 2024).

En todos los casos, la plataforma expone la misma información subyacente a través de dos canales complementarios: la interfaz web para exploración visual y la API REST para automatización, sin que el usuario deba elegir entre accesibilidad y capacidad de integración.

1.5 Alcance del proyecto

DATAQUAL es una plataforma *full-stack* orientada a proyectos de IA y ML, con soporte para conjuntos de datos tabulares en formato CSV. Cubre el ciclo completo de evaluación: carga y versionado de datasets, perfilado exploratorio, ejecución de siete métricas de calidad alineadas con ISO/IEC 25012 (ISO/IEC, 2008), ISO/IEC 25024 (ISO/IEC, 2015) e ISO/IEC 5259 (ISO/IEC, 2024), seguimiento de incidencias entre evaluaciones, *Quality Gates* con veredicto automatizado y protección de datos personales. El sistema se despliega en entorno local mediante Docker Compose y expone una API REST con autenticación JSON Web Token (JWT) para su integración en flujos de trabajo externos.

Quedan **fuera del alcance** del presente trabajo: el procesamiento de conjuntos de datos que excedan la memoria disponible en la máquina de despliegue, la corrección automática de errores y la integración nativa con plataformas *cloud* propietarias (AWS, Azure, GCP).

1.6 Estructura del documento

El presente documento se organiza en siete capítulos y siete anexos. A continuación se describe brevemente el contenido de cada uno de los capítulos restantes:

Capítulo 2: Antecedentes y estado del arte

Revisa los fundamentos teóricos de la calidad de datos, los principales estándares internacionales (ISO/IEC 25012, ISO/IEC 25024 e ISO/IEC 5259), las dimensiones de calidad relevantes y las herramientas existentes en el mercado, identificando las carencias que justifican el desarrollo de DATAQUAL.

Capítulo 3: Objetivos

Define el objetivo general y los objetivos específicos del proyecto, estableciendo el alcance detallado y las restricciones del trabajo.

Capítulo ??: ??

Describe la metodología de gestión y desarrollo adoptada, la pila tecnológica, el backlog inicial, la planificación (Gantt), la estimación de esfuerzo, los costes y la gestión de riesgos.

Capítulo ??: ??

Desarrolla el proceso de implementación iterativo por sprints, incluyendo para cada sprint la planificación, el trabajo realizado, las decisiones técnicas adoptadas y la retrospectiva.

Capítulo ??: ??

Presenta los resultados globales obtenidos, analiza el cumplimiento de los objetivos planteados y compara DATAQUAL con las herramientas existentes.

Capítulo ??: ??

Recoge las conclusiones, la revisión de objetivos, la aportación del proyecto, las competencias adquiridas, la valoración personal y las líneas de trabajo futuro.

El documento incluye siete anexos: especificación completa de la API REST (Anexo A), catálogo de métricas de calidad (Anexo B), backlog completo (Anexo C), plan de riesgos detallado (Anexo D), estimación de costes y viabilidad (Anexo E), manual de usuario (Anexo F) y colección de diagramas Unified Modeling Language (UML) (Anexo G).

Capítulo 2

Antecedentes y estado del arte

Saber que los datos condicionan la calidad de un modelo de IA no basta si no se dispone de una forma sistemática de medirlo. Durante las últimas décadas, la investigación ha producido dos tipos de respuesta: marcos conceptuales y estándares internacionales que definen qué es la calidad de datos, y herramientas que permiten medirla de forma automatizada. Este capítulo revisa ambos frentes para situar DATAQUAL en su contexto: qué se sabe sobre la calidad de datos en IA, qué normas la regulan, qué herramientas ya existen y por qué ninguna cubre exactamente el espacio que DATAQUAL ocupa.

2.1 La importancia de la calidad de datos en proyectos de IA

2.1.1 Marcos conceptuales fundacionales

Los trabajos seminales de Wang y Strong (1996) establecieron un marco conceptual para la calidad de datos basado en cuatro categorías fundamentales:

- **Calidad intrínseca:** precisión, objetividad, credibilidad y reputación de los datos.
- **Calidad contextual:** relevancia, valor añadido, completitud, cantidad apropiada y oportunidad temporal de los datos respecto a la tarea en la que se utilizan.
- **Calidad representacional:** interpretabilidad, facilidad de comprensión, representación concisa y representación consistente.
- **Accesibilidad:** disponibilidad de los datos y seguridad de acceso a los mismos.

El estándar ISO/IEC 25012 recoge el vocabulario conceptual de este marco (completitud, exactitud, consistencia y accesibilidad) rearticulándolo en un modelo orientado a sistemas informáticos que distingue entre características inherentes al dato y características dependientes del entorno tecnológico que lo aloja.

2.1.2 Impacto económico de la mala calidad de datos

Redman (1998) estimó que los errores en datos consumen entre el 8 % y el 12 % de los ingresos de una organización, pudiendo alcanzar entre el 40 % y el 60 % de los gastos operativos en empresas de servicios; investigaciones posteriores del mismo autor (2001) elevaron ese rango hasta el 25 % en sectores con mayor dependencia de datos. Estudios

posteriores del MIT Information Quality Program y del Data Management Body of Knowledge (DMBOK) (DAMA International, 2017) han reproducido estas cifras con resultados similares.

En proyectos de IA, el coste se multiplica: un modelo entrenado con datos defectuosos no solo produce resultados incorrectos, sino que las decisiones tomadas a partir de esas predicciones pueden tener consecuencias financieras, legales y reputacionales difíciles de revertir. Sambasivan et al. (2021) demostraron, en un estudio con 53 equipos de IA de países en desarrollo realizado en Google Research, que el comportamiento de los sistemas de IA está determinado críticamente por los datos, en mayor medida que por el código. Su contribución teórica central es el concepto de *Data Cascades* (cascadas de datos): eventos compuestos originados por problemas de calidad que se propagan y amplifican a lo largo del *pipeline*, causando fallos en etapas posteriores difíciles de trazar hasta su origen. El estudio reveló que el 92 % de los profesionales encuestados había experimentado al menos una cascada de datos. Su trabajo, titulado «Everyone wants to do the model work, not the data work», evidenció la paradoja central del campo: los datos son el factor más determinante del rendimiento y, al mismo tiempo, el aspecto menos valorado del proceso.

Según el *Data Science Report* de CrowdFlower (CrowdFlower, 2016), los científicos de datos dedicaban en 2016 hasta el 60 % de su tiempo a limpiar y organizar datos y un 19 % adicional a recopilarlos, sumando cerca del 80 % en preparación. Encuestas más recientes (Anaconda, Inc., 2022) muestran que ese porcentaje ha descendido hasta aproximadamente el 38 %, pero la preparación y limpieza sigue siendo con diferencia la tarea que más tiempo consume, por encima de la visualización (13 %) y el entrenamiento de modelos (9 %). La tendencia revela un problema estructural que, aunque ha mejorado, sigue siendo el principal cuello de botella del trabajo con datos y refuerza la necesidad de herramientas automatizadas de diagnóstico de calidad.

2.1.3 El paradigma data-centric AI

Ng (2021) acuñó el término *data-centric AI* para describir un giro metodológico respecto al enfoque tradicional *model-centric*: en lugar de mantener los datos fijos y mejorar el algoritmo, se mantiene el modelo fijo y se mejora sistemáticamente el dataset. La premisa es contundente: en la mayoría de proyectos reales de IA, invertir esfuerzo en los datos produce ganancias de rendimiento mayores que afinar la arquitectura del modelo.

Diversas iniciativas han consolidado este paradigma en la comunidad:

- La *Data-Centric AI Competition*, organizada por Andrew Ng y Landing AI, en la que los participantes compiten mejorando un dataset fijo en lugar de un modelo fijo.
- *DataPerf*, una iniciativa de MLCommons que proporciona *benchmarks* centrados en la calidad de datos para sistemas de ML.

- El área de investigación *Data Quality for AI*, que explora métricas de calidad específicas para conjuntos de datos destinados al entrenamiento de modelos.

El paradigma data-centric cobra especial relevancia cuando se considera que los propios datos pueden ser fuente de sesgo sistemático. Los datos desequilibrados o no representativos son la raíz de muchos casos documentados de sesgo en sistemas de IA: desde algoritmos de contratación que discriminan por género (Dastin, 2018) hasta sistemas de reconocimiento facial con tasas de error desproporcionadas para minorías étnicas (Buolamwini and Gebru, 2018). El equilibrio de clases y la representatividad de los datos son factores determinantes en la equidad de los sistemas inteligentes.

2.2 Marco normativo: estándares ISO

La evaluación de la calidad de datos se enmarca dentro de un conjunto de estándares internacionales publicados por la ISO. DATAQUAL toma como referencia conceptual los estándares ISO/IEC 25012 e ISO/IEC 25024, que definen respectivamente el modelo de calidad de datos y sus métricas de medición, y se alinea de forma explícita con ISO/IEC 5259, el estándar específico para calidad de datos en analítica e IA, cuya taxonomía de características estructura las decisiones de alcance del proyecto.

2.2.1 ISO/IEC 25012: Modelo de calidad de datos

El estándar ISO/IEC 25012 (ISO/IEC, 2008) forma parte de la familia Systems and Software Quality Requirements and Evaluation (SQUARE) y define un modelo de calidad de datos que comprende 15 características distribuidas en tres agrupaciones. La **calidad inherente** recoge cinco propiedades intrínsecas del dato (exactitud, completitud, consistencia, credibilidad y actualidad, *currentness*) evaluables con independencia del sistema que los almacena. La **calidad dependiente del sistema** comprende tres propiedades (disponibilidad, portabilidad y recuperabilidad) determinadas por el contexto tecnológico. Una tercera agrupación engloba siete características a la vez inherentes y dependientes del sistema (accesibilidad, conformidad, confidencialidad, eficiencia, precisión, trazabilidad y comprensibilidad), cuya evaluación requiere tanto el análisis del dato como el conocimiento del entorno que lo gestiona.

DATAQUAL implementa métricas que cubren las principales características inherentes del estándar, añadiendo además métricas específicas para proyectos de IA que no están contempladas en la norma. El Cuadro 2.1 muestra la correspondencia entre las características normativas y las métricas implementadas en DATAQUAL.

2.2.2 ISO/IEC 5259: Calidad de datos para analítica e IA

El estándar ISO/IEC 5259 (ISO/IEC, 2024) aborda específicamente la calidad de datos en contextos de analítica e inteligencia artificial y aprendizaje automático. La serie consta

Cuadro 2.1: Correspondencia entre las dimensiones de calidad de ISO/IEC 25012 e ISO/IEC 5259-2 y las métricas implementadas en DATAQUAL

Característica	Norma	Métrica DATAQUAL	Implementación
Complejidad	ISO 25012 + 25024	completeness	Ratio de valores no nulos por columna
Exactitud	ISO 25012 + 25024	syntactic_accuracy	Conformidad con patrones de formato
Consistencia ^a	ISO 5259-2	logical_consistency	Reglas IF-THEN entre columnas
Consistencia ^a	ISO 5259-2 + 25024	uniqueness	Detección de registros duplicados
Actualidad	ISO 5259-2	currentness	Antigüedad del dato más reciente
<i>Características adicionales para IA (ISO/IEC 5259-2)</i>			
Equilibrio (Balance)	ISO 5259-2	class_balance	Entropía de Shannon
Diversidad	ISO 5259-2	diversity	Cobertura de valores esperados por columna

^a La consistencia se operacionaliza en dos métricas: coherencia lógica entre columnas y ausencia de duplicados, siguiendo las sub-dimensiones Con-ML-4 y Con-ML-1 de ISO/IEC 5259-2 respectivamente.

de cinco partes, de las cuales la Parte 2 (medidas de calidad de datos) fue publicada en noviembre de 2024 (ISO/IEC, 2024):

1. **Parte 1. Visión general:** establece los conceptos fundamentales y el vocabulario común.
2. **Parte 2. Métricas de calidad de datos:** define métricas cuantitativas estandarizadas para evaluar la calidad de datos destinados a sistemas de IA.
3. **Parte 3. Gestión de datos:** cubre la gestión de conjuntos de datos, incluyendo versionado y trazabilidad.
4. **Parte 4. Marco de procesos:** describe el flujo de evaluación integrado en el ciclo de vida de un proyecto de IA.
5. **Parte 5. Verificación y validación:** establece los requisitos para verificar y validar los procesos y resultados de evaluación de calidad de datos.

DATAQUAL se alinea con este estándar en varios aspectos: proporciona métricas cuantitativas estandarizadas (Parte 2), implementa gestión de datasets con versionado (Parte 3) y ofrece un flujo de evaluación integrado en el ciclo de vida del proyecto (Parte 4).

Desde el punto de vista del alcance, la contribución más relevante de ISO/IEC 5259-2 es la organización de las características de calidad en cuatro grupos según su naturaleza y su dependencia del contexto tecnológico: *características inherentes*, *características mixtas* (inherentes y dependientes del sistema), *características dependientes del sistema* y *características adicionales* específicas para IA/ML. Esta taxonomía, analizada en detalle en la

Sección 2.3, constituye el marco conceptual sobre el que se delimita el alcance técnico de DATAQUAL.

2.2.3 ISO/IEC 25024: Medición de la calidad de datos

El estándar ISO/IEC 25024 (ISO/IEC, 2015) complementa al 25012 proporcionando métricas concretas y fórmulas de medición para cada característica de calidad. De este modo, se pasa de un modelo conceptual abstracto a un conjunto de indicadores cuantificables.

DATAQUAL implementa directamente tres de las métricas definidas en este estándar: el **ratio de completitud** (proporción de valores no nulos sobre el total de valores esperados en una columna o dataset), el **ratio de unicidad** (proporción de valores únicos respecto al total de registros, utilizada para detectar duplicados) y el **ratio de conformidad sintáctica** (proporción de valores que se ajustan a un patrón o formato predefinido mediante expresiones regulares, rangos numéricos o conjuntos de valores permitidos).

La adopción de estas fórmulas estandarizadas garantiza que los resultados de DATAQUAL sean comparables con los obtenidos por otras herramientas que implementen el mismo estándar, facilitando la comparabilidad entre herramientas y la auditoría de resultados.

El Reglamento Europeo de Inteligencia Artificial (Parlamento Europeo y Consejo de la Unión Europea, 2024) refuerza la relevancia del conjunto de estándares descrito en esta sección: exige que las organizaciones puedan demostrar la calidad y trazabilidad de los datos utilizados en sus modelos, lo que convierte la evaluación estandarizada de calidad de datos en una necesidad no solo técnica, sino también de cumplimiento normativo.

2.3 Alcance metodológico: selección y priorización de características en el Minimum Viable Product (MVP)

El marco normativo descrito en la sección anterior permite estructurar las decisiones de alcance de DATAQUAL en dos niveles. El primero distingue qué características son evaluables sobre el fichero de datos y cuáles requieren acceso a infraestructura o metadatos externos, criterio derivado directamente de la taxonomía de ISO/IEC 5259-2 (ISO/IEC, 2024). El segundo nivel responde a decisiones de priorización del MVP: algunas características técnicamente evaluables no fueron incluidas en esta versión por razones de alcance del proyecto, quedando como trabajo futuro. La presente sección detalla ambos criterios.

2.3.1 Taxonomía de características de calidad según ISO/IEC 5259-2

ISO/IEC 5259-2 organiza las características de calidad de datos para analítica e IA en cuatro grupos según su naturaleza y su grado de dependencia del contexto tecnológico:

- **Características inherentes** (5): exactitud (*accuracy*), completitud (*completeness*), consistencia (*consistency*), credibilidad (*credibility*) y actualidad (*currentness*). Son propiedades intrínsecas del dato, evaluables a partir del análisis de sus valores sin necesi-

dad de conocer el sistema que lo aloja.

- **Características mixtas (7):** accesibilidad (*accessibility*), conformidad (*compliance*), eficiencia (*efficiency*), precisión (*precision*), trazabilidad (*traceability*), confidencialidad (*confidentiality*) y comprensibilidad (*understandability*). Dependen tanto de las propiedades del dato como del contexto del sistema que lo gestiona.
- **Características dependientes del sistema (3):** disponibilidad (*availability*), portabilidad (*portability*) y recuperabilidad (*recoverability*). Vienen determinadas exclusivamente por la infraestructura tecnológica de la organización.
- **Características adicionales para IA/ML (9):** equilibrio (*balance*), diversidad (*diversity*), efectividad (*effectiveness*), identificabilidad (*identifiability*), relevancia (*relevance*), representatividad (*representativeness*), similitud (*similarity*), puntualidad (*timeliness*) y auditabilidad (*auditability*). Abordan necesidades específicas del aprendizaje automático que los marcos generalistas de calidad de datos no contemplan.

El Cuadro 2.2 sintetiza la cobertura de DATAQUAL respecto a las cuatro categorías anteriores.

2.3.2 Características evaluables algorítmicamente

Las características inherentes de ISO/IEC 5259-2 son evaluables algorítmicamente porque sus métricas se calculan a partir de los propios valores del dataset, sin necesidad de acceder a sistemas externos ni de conocer el dominio de negocio. La completitud se mide como la proporción de valores no nulos; la exactitud sintáctica, como la conformidad con patrones de formato definidos; la consistencia, como la ausencia de contradicciones lógicas entre columnas (sub-dimensión Con-ML-4 de ISO/IEC 5259-2) y como la ausencia de registros duplicados (sub-dimensión Con-ML-1); y la actualidad, como la antigüedad del valor más reciente en columnas temporales. Del grupo de características adicionales, el equilibrio de clases (*balance*) y la diversidad (*diversity*) son también evaluables algorítmicamente: el primero se cuantifica mediante la entropía de Shannon sobre los valores de la columna objetivo, y el segundo mide la cobertura de los valores y rangos esperados definidos por el usuario.

Esta propiedad de *auto-contención* es lo que hace posible desarrollar una herramienta de análisis y evaluación que opera exclusivamente sobre el fichero de datos sin requerir integración con los sistemas de la organización. El motor de métricas de DATAQUAL explota esta característica al procesar cada AnalysisRun de forma asíncrona y aislada, leyendo el dataset almacenado en MinIO y calculando las métricas configuradas sin acceso a los sistemas propios de la organización propietaria del dataset.

Cuadro 2.2: Cobertura de DATAQUAL respecto al modelo de calidad de ISO/IEC 5259-2

Categoría	Características	DATAQUAL	Motivo
Inherentes	Exactitud, Completitud, Consistencia, Actualidad	Implementadas	Extraíbles del dataset sin contexto externo
	Credibilidad	Fuera de alcance	No priorizada en el MVP; candidata para versiones futuras
Mixtas	Accesibilidad, Conformidad, Eficiencia, Precisión, Trazabilidad, Confidencialidad, Comprensibilidad	Fuera de alcance	Requieren información del sistema que aloja el dato
Dep. del sistema	Disponibilidad, Portabilidad, Recuperabilidad	Fuera de alcance	Determinadas por la infraestructura TI de la organización
Adicionales (impl.)	Equilibrio (<i>class_balance</i>), Diversidad (<i>diversity</i>)	Implementadas	Impacto directo en fiabilidad y cumplimiento normativo de modelos de IA
Adicionales (téc.)	Efectividad, Relevancia, Representatividad, Similitud	Fuera de alcance	Requieren metadatos organizativos externos al fichero de datos
Adicionales (futuro)	Identificabilidad, Auditabilidad, Puntualidad	Fuera de alcance	No priorizadas en el MVP; candidatas para versiones futuras

2.3.3 Características fuera del alcance del proyecto

Las características no implementadas en DATAQUAL responden a dos motivos distintos: imposibilidad técnica estructural y decisiones de priorización del MVP. Los tres primeros párrafos describen características técnicamente inviables sin acceso a infraestructura o metadatos externos; el último recoge las que quedaron fuera por decisión de alcance del proyecto.

Dependencia de infraestructura organizativa. Las características dependientes del sistema (disponibilidad, portabilidad y recuperabilidad) no describen propiedades del dato en sí, sino de la infraestructura que lo almacena y sirve. La *disponibilidad* mide si el dataset puede ser recuperado por usuarios autorizados dentro de un plazo acordado, lo que remite a acuerdos de nivel de servicio (Service Level Agreement (SLA)) y arquitecturas de almacenamiento. La *portabilidad* evalúa la capacidad de mover el dato entre sistemas preservando su calidad, lo que requiere acceso a los conectores y formatos de exportación propietarios de la organización. La *recuperabilidad* depende de las políticas de copia de seguridad y los mecanismos de restauración de datos. Ninguna de estas características puede evaluarse analizando el contenido de un fichero: exigen acceso al entorno operativo de la organización, del que una herramienta de análisis externa no dispone por definición.

Características mixtas con dependencia del sistema. Las siete características mixtas (accesibilidad, conformidad, eficiencia, precisión, trazabilidad, confidencialidad y comprensibilidad) dependen tanto de las propiedades del dato como del entorno tecnológico que lo gestiona. Su evaluación requiere información sobre el sistema que aloja el dato: los controles de acceso para la accesibilidad, los estándares aplicables para la conformidad, o las políticas de uso para la comprensibilidad. Sin acceso a esa capa de contexto organizativo, su medición no puede realizarse sobre el fichero de datos de forma aislada.

Dependencia de metadatos organizativos y contexto de negocio. Un subconjunto de las características adicionales requiere información que trasciende el fichero de datos. La *representatividad* necesita la definición de la población objetivo del modelo, que es un requisito de negocio no inscrito en el dato. La *relevancia* y la *efectividad* requieren un diccionario de datos y políticas de gobernanza privadas para determinar si el dataset es adecuado para la tarea prevista. La *similitud* presupone un conocimiento del espacio de características del dominio que no resulta accesible sin la colaboración directa de la organización propietaria.

Decisiones de priorización del MVP. Algunas características técnicamente evaluables no fueron incluidas en esta versión por razones de alcance del proyecto. La *credibilidad*

requiere la verificación de la procedencia de los datos, lo que, aunque factible, no se consideró prioritario para el caso de uso objetivo. La *identificabilidad*, la *auditabilidad* y la *puntualidad* son candidatas a implementarse en versiones futuras de DATAQUAL.

2.3.4 Priorización de características para el MVP

Entre las características algorítmicamente evaluables, el desarrollo del MVP de DATAQUAL ha priorizado aquellas con mayor impacto en la fiabilidad de los modelos de IA y en el cumplimiento del marco normativo aplicable:

1. **Las características inherentes de ISO/IEC 25012** (completitud, exactitud, consistencia y actualidad) implementadas a través de cinco métricas: *completeness*, *syntactic_accuracy*, *logical_consistency*, *currentness* y *uniqueness*, siendo esta última la sub-dimensión Con-ML-1 de consistencia definida en ISO/IEC 5259-2. Esto proporciona cobertura directa de los requisitos de ISO/IEC 5259-2 (ISO/IEC, 2024) e ISO/IEC 25024 (ISO/IEC, 2015).
2. **Equilibrio de clases** (*class_balance*), medido mediante la entropía de Shannon. El desequilibrio de clases es uno de los factores documentados de sesgo en sistemas de IA (Buolamwini and Gebru, 2018; Dastin, 2018) y su corrección tiene un impacto directo en la equidad y fiabilidad de los modelos de clasificación.
3. **Diversidad del dataset** (*diversity*): evalúa, de forma *opt-in* con expectativas definidas por el usuario, si el dataset cubre los valores y rangos esperados por columna, detectando valores ausentes, categorías sub-representadas e intervalos numéricos sin datos, lo que puede comprometer la capacidad de generalización de los modelos entrenados con ese conjunto (ISO/IEC, 2024).

Adicionalmente, los valores atípicos (*outliers*) se han incorporado como herramienta de diagnóstico en el módulo de Exploratory Data Analysis (EDA), sin ser computados como parte de la puntuación de calidad global. Esta decisión sigue explícitamente la recomendación de ISO/IEC 5259-2 (ISO/IEC, 2024), que no considera los *outliers* una dimensión de calidad inherente, sino un indicador diagnóstico cuya relevancia depende del dominio de aplicación.

El resultado es una delimitación deliberada del alcance del proyecto: DATAQUAL proporciona una evaluación algorítmica y estadística de las características de calidad priorizadas para proyectos de IA, aquellas medibles directamente sobre el fichero de datos con mayor impacto en la fiabilidad de los modelos. Las características que requieren infraestructura externa, metadatos organizativos o que no fueron priorizadas en el MVP quedan fuera de su ámbito actual, configurándose como líneas de trabajo futuro.

2.4 Estado del arte: herramientas existentes

Para contextualizar la contribución de DATAQUAL es necesario conocer qué existe ya. Las herramientas descritas a continuación representan el estado del arte en evaluación de calidad de datos; sus fortalezas y sus límites definen el espacio en el que DATAQUAL opera.

2.4.1 Great Expectations

Great Expectations (Great Expectations, 2024) es una biblioteca de código abierto escrita en Python para la definición y validación de «expectativas» (*expectations*) sobre conjuntos de datos. Las expectativas son aserciones declarativas que describen las propiedades que se esperan de los datos, como «esta columna no debe contener valores nulos» o «los valores de esta columna deben estar comprendidos entre 0 y 100».

Fortalezas. Great Expectations cuenta con un ecosistema maduro y una comunidad activa. Soporta múltiples *backends* de ejecución (Pandas, Spark, SQL), lo que permite evaluar datasets de distintos tamaños y procedencias. Además, genera automáticamente documentación visual de los resultados de validación (*Data Docs*).

Limitaciones. Se trata de una herramienta *code-first* que requiere conocimientos de Python para su configuración y uso. La versión de código abierto no dispone de interfaz gráfica integrada; GX Cloud ofrece una interfaz web gestionada pero como servicio externo (*SaaS*), sin posibilidad de autoalojamiento. No ofrece Quality Gates nativos con estado global configurable, no implementa un sistema de rastreo de issues entre ejecuciones sucesivas y presenta una curva de aprendizaje pronunciada para equipos sin experiencia en programación.

2.4.2 Apache Deequ

Apache Deequ (Schelter et al., 2018) es una biblioteca de verificación de calidad de datos desarrollada por Amazon y construida sobre Apache Spark. Está diseñada para operar a gran escala sobre datasets masivos en entornos distribuidos.

Fortalezas. Su principal ventaja es la escalabilidad masiva que hereda de Spark, lo que permite procesar datasets de millones de registros de forma distribuida. Ofrece integración nativa con los servicios de Amazon Web Services, verificación declarativa de restricciones y detección de anomalías basada en series temporales.

Limitaciones. Requiere un entorno JVM y un clúster de Spark para su ejecución, lo que supone una barrera de entrada considerable. No dispone de interfaz web, resulta desproporcionado para datasets de tamaño medio y no implementa métricas específicas para proyectos de IA como el equilibrio de clases.

2.4.3 DQOps

DQOps (DQOps, 2024) es una herramienta de calidad de datos de código abierto inspirada en la filosofía de SonarQube (SonarSource, 2024). Proporciona un enfoque sistemático a la calidad de datos con monitorización continua y alertas automatizadas.

Fortalezas. DQOps comparte una filosofía similar a la de DATAQUAL en cuanto al tratamiento de la calidad de datos como un proceso continuo. Soporta múltiples fuentes de datos (BigQuery, Snowflake, PostgreSQL), ofrece una interfaz web para la configuración y visualización de resultados, y permite definir alertas automatizadas ante degradaciones de calidad.

Limitaciones. Su configuración es compleja dado el elevado número de checks disponibles. Aunque incorpora soporte para ficheros planos (CSV, Parquet) a través de DuckDB, su enfoque principal es la monitorización continua de fuentes de datos conectadas. No ha sido diseñado específicamente para proyectos de IA y carece de métricas específicas como el equilibrio de clases o la diversidad de los datos de entrenamiento.

2.4.4 Soda Core

Soda Core (Soda Data, Inc., 2024) es un *framework* de código abierto (licencia Apache 2.0) para la validación y monitorización continua de la calidad de datos. Los controles de calidad se expresan en Soda Checks Language (SODACL), un lenguaje declarativo basado en YAML Ain't Markup Language (YAML) de sintaxis legible sin necesidad de programar en Python. Cuenta con respaldo comercial de Soda Data, Inc. y se integra de forma nativa con orquestadores habituales como Apache Airflow y dbt.

Fortalezas. Soda Core soporta un amplio abanico de fuentes de datos: bases de datos relacionales (PostgreSQL, BigQuery, Snowflake) y ficheros tabulares mediante integración con pandas (CSV, Parquet). Su lenguaje SODACL reduce la barrera técnica respecto a herramientas *code-first*. La versión comercial Soda Cloud añade una interfaz web de visualización, comparación histórica de resultados y *Quality Gates* con notificaciones automatizadas.

Limitaciones. La interfaz web está disponible únicamente en el nivel comercial (Soda Cloud), por lo que el uso puramente *open source* se limita a la línea de comandos. Soda Core carece de métricas específicas para IA (equilibrio de clases, detección de valores atípicos orientada a modelos) y no implementa *fingerprinting* de issues entre ejecuciones ni ocultación nativa de datos sensibles (Personally Identifiable Information (PII)).

2.4.5 Otras herramientas relevantes

Herramientas comerciales. Existen soluciones comerciales orientadas a la preparación de datos, como Alteryx (Alteryx, Inc., 2024) y Talend (Qlik Technologies, Inc., 2024). Estas herramientas ofrecen interfaces gráficas pulidas, capacidades de transformación (*data wrangling*) y soporte empresarial, pero presentan limitaciones significativas para el caso de uso de DATAQUAL: coste de licenciamiento elevado, dependencia del proveedor (*vendor lock-in*) y operación mayoritaria como Software as a Service (SAAS), lo que impide que la organización controle dónde residen sus datos. Además, su foco es la transformación de datos, no la evaluación de calidad para proyectos de IA.

Herramientas orientadas a ML. Evidently AI (Evidently AI, 2024) es una biblioteca *open source* específicamente diseñada para la monitorización de datos y modelos de ML: detecta *data drift*, evalúa el equilibrio de clases y genera informes visuales en HTML. Su enfoque está orientado a la comparación distribucional entre conjuntos de referencia y producción, más que a la auditoría estática de un fichero puntual. Pandera (Union.ai and Pandera Contributors, 2024) ofrece validación esquemática de *DataFrames* de pandas mediante anotaciones de tipo, útil en la etapa de pruebas del *pipeline* pero sin interfaz gráfica ni historial de ejecuciones. ydata-profiling (ydata-ai, 2024) genera informes exploratorios exhaustivos en HTML a partir de un fichero de datos, con estadísticas descriptivas, correlaciones y alertas básicas de calidad, pero sin motor de evaluación configurable ni Quality Gates.

2.4.6 Análisis comparativo

El Cuadro 2.3 presenta una comparación sistemática de DATAQUAL con las cuatro herramientas de código abierto analizadas. Se han seleccionado dieciséis características que cubren la funcionalidad, la accesibilidad, las capacidades específicas para IA y los aspectos operativos.

Como se puede observar, DATAQUAL ocupa un nicho diferenciado al combinar una interfaz web completa, de uso libre, con métricas específicas para IA, *fingerprinting* de issues, versionado de datasets e interfaz multiidioma (español e inglés), un conjunto de capacidades que ninguna de las herramientas analizadas ofrece en su totalidad. La cifra de métricas predefinidas no es directamente comparable entre herramientas: Great Expectations y DQOps contabilizan aserciones atómicas individuales (una por cada regla o patrón sobre una columna concreta), mientras que DATAQUAL implementa siete dimensiones de calidad de alto nivel alineadas con ISO/IEC 5259-2, cada una configurable para evaluar cualquier número de columnas y reglas. Este enfoque basado en dimensiones normalizadas produce resultados comparables entre proyectos y equipos; las aserciones atómicas son, por el contrario, específicas de cada dataset y requieren definición manual por parte del desarrollador. Además, Great Expectations presenta una naturaleza *code-first* que limita su accesibilidad a usuarios

Cuadro 2.3: Comparativa de DATAQUAL con herramientas de calidad de datos existentes

Característica	DATAQUAL	Gr. Exp.	Deequ	DQOps	Soda
Interfaz web	Sí	Parcial ^b	No	Sí	Parcial ^a
Interfaz multiidioma	Sí	—	—	No	No
Requiere programación	No	Sí	Sí	Parcial	No
Métricas predefinidas	7	300+	20+	260+	30+
Detección automática de tipos	Sí	No	No	Parcial	Parcial
Quality Gates	Sí	No	No	Sí	Sí
Fingerprinting de issues	Sí	No	No	No	No
Comparación entre ejecuciones	Sí	No	Sí	Sí	Sí
Equilibrio de clases	Sí	No	No	No	No
Detección de outliers	Sí	Parcial	Sí	Parcial	No
Enmascaramiento de PII	Sí	No	No	No	No
Versionado de datasets	Sí	No	No	No	No
Procesamiento asíncrono	Sí	No	Sí	Sí	Sí
Autoalojable	Sí	Sí	Sí	Sí	Sí
Específico para IA/ML	Sí	No	No	No	No
Coste	Libre	Freemium	Libre	Freemium	Freemium

^a La interfaz web de Soda (Soda Cloud) está disponible únicamente en el nivel comercial. ^b GX Cloud proporciona una interfaz web gestionada (*SaaS*) con nivel gratuito para desarrolladores y planes de pago para equipos.

no técnicos. Apache Deequ ofrece escalabilidad masiva, pero a costa de una complejidad operativa que lo hace inviable para conjuntos de datos de tamaño moderado. DQOps y Soda Core comparten la filosofía de calidad continua y disponen de *Quality Gates*, pero ambos orientan su análisis principalmente a fuentes de datos conectadas y carecen de métricas específicas para IA. Soda Core relega además su interfaz web al nivel comercial de pago, mientras que DQOps sí ofrece una interfaz web gratuita en local, aunque sin las capacidades de colaboración en equipo de su versión en la nube.

2.5 Diferenciación de DATAQUAL

El análisis anterior revela un espacio concreto que ninguna herramienta cubre en su totalidad. DATAQUAL lo ocupa a través de ocho capacidades que, tomadas en conjunto, no tienen equivalente directo en el ecosistema *open source*:

1. **Solución *full-stack* con interfaz integrada y gratuita.** Mientras que Great Expectations y Apache Deequ son herramientas *code-only* y Soda Core reserva su interfaz web al nivel comercial de pago, DATAQUAL proporciona una interfaz web completa construida con React (Meta Platforms, Inc., 2024) y Next.js (Vercel, 2024) disponible sin coste de licencia y autoalojable, que permite a usuarios no técnicos configurar métricas, lanzar evaluaciones y consultar resultados sin escribir código.
2. **Diseño centrado en IA.** DATAQUAL incorpora métricas específicas para proyectos de aprendizaje automático que no se encuentran en las herramientas generalistas: equili-

brio de clases (`class_balance`, entropía de Shannon) y diversidad del dataset (`diversity`), orientada a detectar subrepresentación de valores o rangos esperados por columna.

3. **Interfaz multiidioma.** La plataforma soporta español e inglés con cambio de idioma en tiempo real, lo que amplía su accesibilidad a equipos internacionales sin coste adicional de configuración.
4. **Sistema de fingerprinting SHA-256.** Inspirado en SonarQube (SonarSource, 2024), DATAQUAL genera un hash Secure Hash Algorithm (SHA)-256 para cada issue detectado, lo que permite rastrear su ciclo de vida a lo largo de múltiples ejecuciones: issues nuevos, recurrentes y corregidos.
5. **Quality Gates como puntos de decisión.** Cada evaluación produce un veredicto global (PASSED, WARNING o FAILED) basado en umbrales configurables, proporcionando una señal inequívoca sobre la aptitud del dataset para su uso.
6. **Protección de PII integrada.** La ocultación de los valores de columnas sensibles en todos los outputs de la plataforma es una funcionalidad nativa, no un complemento externo. Esto facilita el cumplimiento del RGPD y otras normativas de protección de datos.
7. **Arquitectura de plugins extensible.** El motor de métricas se basa en una clase abstracta `BaseMetric` y un registro global (`METRIC_REGISTRY`) que permiten añadir nuevas métricas sin modificar el código existente, siguiendo el principio abierto-cerrado de los patrones de diseño (Gamma et al., 1994).
8. **Autoalojamiento con soberanía de datos.** DATAQUAL se despliega mediante Docker Compose (Docker, Inc., 2024) sin dependencias de servicios en la nube. Todos los datos permanecen en la infraestructura del usuario, lo que garantiza que los datos permanecen en la infraestructura del usuario y facilita el cumplimiento normativo.

2.6 Justificación académica

DATAQUAL no es un ejercicio de una sola disciplina. Su desarrollo ha requerido conocimientos de varias áreas del Grado en Ingeniería Informática:

Arquitectura de software y sistemas distribuidos. El proyecto despliega ocho servicios orquestados con Docker Compose (Docker, Inc., 2024), sin dependencias de infraestructura en la nube. El *backend* estructura la lógica según el patrón Model-View-Controller (MVC) sobre Flask (Ronacher, 2024) y aplica dos patrones del catálogo clásico (Gamma et al., 1994): Strategy en la clase abstracta `BaseMetric` y Registry en `METRIC_REGISTRY`, ambos bajo el principio abierto-cerrado. Un *middleware* propio, `EvaluationWatchdog`, ejecuta un hilo de fondo que detecta evaluaciones bloqueadas y las retoma sin intervención manual.

Capa de datos y procesamiento asíncrono. La capa de persistencia usa PostgreSQL (The PostgreSQL Global Development Group, 2024) con campos JSONB para configuraciones flexibles, SQLAlchemy (Bayer, 2024) como Object-Relational Mapping (ORM) con migraciones versionadas en Alembic, y MinIO (MinIO, Inc., 2024) como almacén de objetos compatible con S3. Las evaluaciones se procesan de forma asíncrona con Celery (Celery Project, 2024), usando Redis (Redis Ltd., 2024) como *broker*; Flower monitoriza el estado de los *workers* en tiempo real. Cuando Celery no está disponible, HybridEvaluationService ejecuta la evaluación en un hilo local como *fallback*.

Frontend y comunicación cliente-servidor. La interfaz se construye con React (Meta Platforms, Inc., 2024), Next.js (Vercel, 2024), TypeScript (Microsoft, 2024) y Material User Interface (UI) (MUI, 2024), y se comunica con el *backend* a través de una API REST protegida con JWT. Las visualizaciones interactivas —gráficos de líneas, barras, *doughnut* y *scatter*— se implementan con Chart.js (Chart.js Contributors, 2024) mediante su adaptador para React. La internacionalización (español e inglés con cambio en tiempo real) se gestiona con react-i18next.

Estadística aplicada y análisis exploratorio. El motor de métricas usa la entropía de Shannon para medir el equilibrio de clases: produce un valor entre 0 y 100 donde 100 indica distribución uniforme y los valores próximos a 0 señalan desequilibrio severo. El módulo de EDA detecta valores atípicos con el Interquartile Range (IQR) y ofrece histogramas, diagramas de caja, gráficos de barras y matrices de correlación (Pearson y Spearman).

Seguridad y cumplimiento normativo. La plataforma usa autenticación JWT y derivación de contraseñas con Password-Based Key Derivation Function 2 (PBKDF2), y limita la tasa de peticiones con Flask-Limiter, respaldado por Redis en el despliegue con Docker Compose. La validación de entradas en los puntos críticos se realiza con esquemas Marshmallow; las reglas de consistencia lógica se filtran mediante una lista de tokens prohibidos para evitar la ejecución de código arbitrario. Las columnas marcadas como PII se enmascaran en todos los *outputs* de evaluación, lo que facilita el cumplimiento del RGPD.

Cada una de estas áreas ha dejado huella directa en la arquitectura: las decisiones de una capa condicionan las de las demás, lo que convierte el proyecto en un ejercicio de integración real, no solo de aplicación aislada de conocimientos.

Capítulo 3

Objetivos

El análisis del capítulo 2 permite delimitar los objetivos que guían el desarrollo de DATAQUAL: el objetivo general, cinco objetivos específicos que cubren las principales dimensiones funcionales, los objetivos transversales de calidad del software y el alcance del proyecto con sus limitaciones.

3.1 Objetivo general

El objetivo general de este TFG consiste en **diseñar, implementar y validar una plataforma web interactiva y una API RESTful que permitan evaluar de forma automatizada la calidad de los datos empleados en proyectos de IA**, proporcionando métricas cuantitativas, visualizaciones interactivas y mecanismos de diagnóstico que faciliten la identificación y corrección de problemas de calidad en los conjuntos de datos.

Este objetivo responde a la necesidad, identificada en la sección 1.1, de disponer de herramientas que superen las limitaciones de los enfoques ad hoc (*scripts* puntuales, consultas SQL manuales o inspecciones en cuadernos Jupyter) y que, al mismo tiempo, no impongan la barrera técnica que presentan las bibliotecas basadas exclusivamente en código (sección 2.4). DATAQUAL ofrece una solución *full-stack*, alineada con los estándares ISO/IEC 25012 (ISO/IEC, 2008) e ISO/IEC 5259 (ISO/IEC, 2024), que hace accesible la evaluación de calidad de datos sin necesidad de escribir código.

3.2 Objetivos específicos

El objetivo general se descompone en los siguientes cinco objetivos específicos (**OE1–OE5**), cada uno de los cuales aborda una dimensión funcional diferenciada de la plataforma.

3.2.1 OE1. Módulo de ingesta y almacenamiento

Antes de evaluar la calidad de un dataset, la plataforma debe ser capaz de recibirlo, interpretarlo y custodiarlo de forma fiable. Este requisito, aparentemente sencillo, esconde una dificultad práctica recurrente: los archivos CSV del mundo real presentan combinaciones heterogéneas de codificaciones, delimitadores y convenciones de formato que los analiza-

dores estándar no resuelven sin configuración explícita. Ignorar este problema implica que una fracción significativa de los datasets reales sería rechazada en la entrada, invalidando la utilidad de cualquier análisis posterior.

El objetivo consiste en desarrollar un módulo de ingesta y almacenamiento que resuelva este problema de forma transparente para el usuario, sin requerir conocimiento técnico sobre el formato del fichero. Los requisitos que lo concretan son los siguientes:

- **Soporte CSV.** La plataforma acepta conjuntos de datos en formato CSV, el formato tabular más extendido en proyectos de IA y ciencia de datos.
- **Parseo robusto.** El módulo implementa una estrategia de *fallback* que combina múltiples codificaciones (UTF-8, UTF-8-BOM, CP1252, Latin-1), separadores (coma, punto y coma, tabulador, *pipe*) y motores de lectura, garantizando la ingesta correcta del mayor número posible de archivos reales sin intervención del usuario.
- **Almacenamiento seguro.** Los archivos originales se almacenan en un sistema de objetos compatible con S3 (MinIO) para garantizar su integridad y disponibilidad; los metadatos (esquema, estadísticas descriptivas y conteos) se persisten en PostgreSQL para permitir consultas eficientes.
- **Extracción automática de esquema.** El sistema infiere automáticamente los nombres de columna, los tipos de dato y las estadísticas descriptivas básicas de cada dataset cargado, eliminando la necesidad de configuración manual previa a la evaluación.
- **Versionado de conjuntos de datos.** El módulo soporta la carga de nuevas versiones de un mismo dataset, manteniendo la trazabilidad entre versiones mediante una relación padre-hijo y un indicador de versión activa.

3.2.2 OE2. Motor de evaluación con métricas parametrizables

El núcleo funcional de DATAQUAL es su motor de evaluación. Las herramientas generalistas de calidad de datos ofrecen métricas orientadas a bases de datos transaccionales (completitud, unicidad, conformidad de formato), pero carecen de las dimensiones específicas que condicionan el rendimiento de un modelo de IA: el desequilibrio entre clases introduce sesgo sistemático, y la falta de representatividad de ciertos valores o rangos compromete la capacidad de generalización. Este objetivo cubre ambos frentes: las dimensiones estándar definidas por los organismos normativos y las dimensiones propias del contexto de ML.

El motor debe cubrir las dimensiones de calidad de ISO/IEC 25012 (ISO/IEC, 2008), aplicando las fórmulas de medición definidas en ISO/IEC 25024 (ISO/IEC, 2015), y añadir las métricas específicas para IA de ISO/IEC 5259 (ISO/IEC, 2024). Las **siete métricas evaluables** que contribuyen al *Quality Score* son:

1. **Completitud** (completeness): ratio de valores no nulos por columna, alineada con la característica de completitud de ISO/IEC 25012.

2. **Exactitud sintáctica** (*syntactic_accuracy*): conformidad de los valores con patrones de formato definidos mediante expresiones regulares, correspondiente a la dimensión de exactitud.
3. **Consistencia lógica** (*logical_consistency*): verificación de reglas condicionales entre columnas (reglas IF - THEN), alineada con la dimensión de consistencia.
4. **Actualidad** (*currentness*): antigüedad del dato más reciente respecto a un instante de referencia, correspondiente a la dimensión de actualidad (*currentness*).
5. **Unicidad** (*uniqueness*): detección de registros duplicados, implementando la sub-dimensión Con-ML-1 de consistencia definida en ISO/IEC 5259-2.
6. **Equilibrio de clases** (*class_balance*): evaluación del balance de la variable objetivo mediante la entropía de Shannon, métrica específica para proyectos de IA que permite detectar desequilibrios que sesgan los modelos (Ng, 2021).
7. **Diversidad del dataset** (*diversity*): evaluación, de forma *opt-in* con expectativas definidas por el usuario, de si el dataset cubre los valores y rangos esperados por columna, detectando subrepresentación que puede comprometer la capacidad de generalización de los modelos (ISO/IEC, 2024).

Adicionalmente, el motor debe incluir una clase de **detección de valores atípicos** (*outliers*) basada en el IQR (Tukey, 1977). Siguiendo la recomendación de ISO/IEC 5259 (ISO/IEC, 2024) de no tratar los *outliers* como una dimensión de calidad per se (su relevancia depende del dominio de aplicación), esta clase **no participará en el *Quality Score*** sino que se utilizará exclusivamente como herramienta de diagnóstico en el módulo de perfilado de datos (EDA).

El motor debe adoptar una arquitectura de *plugins*, de modo que cada métrica se implemente como una clase independiente que herede de una clase base abstracta y se registre dinámicamente en un registro centralizado. Esta arquitectura garantiza la extensibilidad del sistema, permitiendo incorporar nuevas métricas sin modificar el núcleo del motor.

Adicionalmente, cada métrica debe ser parametrizable: umbrales de aceptación, columnas objetivo, métodos de detección y pesos relativos (en una escala de 0,0 a 1,0) que determinen su contribución a la puntuación global de calidad. El sistema debe soportar también plantillas de métricas que permitan reutilizar configuraciones entre proyectos.

3.2.3 OE3. API RESTful con especificación formal

Una plataforma de evaluación de calidad de datos no debería ser un sistema cerrado: su valor aumenta cuando puede integrarse en *pipelines* de Machine Learning Operations (MLOPS), en procesos de integración continua o en herramientas externas que consuman sus resultados de forma programática. Para ello es necesario que la API esté bien estructurada y cuente con una especificación explícita que permita a terceros integrarla sin necesidad

de leer el código fuente.

El objetivo consiste en diseñar e implementar una API RESTful que exponga *endpoints* para la carga de datos, configuración de evaluaciones, ejecución de análisis y consulta de resultados. La especificación completa de rutas, parámetros y formatos de respuesta se recoge en el Anexo A; este objetivo define el alcance funcional que dicha especificación debe cubrir.

La API se organiza en seis módulos funcionales cohesivos, siguiendo el patrón *Blueprint* de Flask:

auth Registro de usuarios, inicio de sesión, refresco de *tokens* JWT y consulta del perfil del usuario autenticado.

projects

Operaciones Create, Read, Update, Delete (CRUD) sobre proyectos, incluyendo la asignación de conjuntos de datos y la configuración de métricas.

datasets

Carga de conjuntos de datos, consulta de metadatos, gestión de versiones y descarga de archivos.

metrics

Definición y configuración de métricas de calidad, gestión de plantillas y consulta del catálogo de métricas disponibles.

evaluations

Lanzamiento de evaluaciones, consulta de progreso, recuperación de resultados e *issues* detectados.

admin

Utilidades de administración del sistema, incluyendo un *endpoint* de comprobación de salud (*health check*).

Todos los *endpoints* protegidos requieren autenticación mediante JWT. El formato de respuesta es uniforme y predecible, con la estructura {success, data, message} y soporte de paginación en los listados. La convención REST de rutas anidadas añade *blueprints* técnicos adicionales (project_metrics, project_datasets, dashboard, patterns) que no amplían el alcance funcional pero sí el número total de *blueprints* registrados.

3.2.4 OE4. Aplicación web con *dashboards* interactivos

Una API potente pero sin interfaz gráfica reproduce exactamente la barrera de acceso que DATAQUAL pretende eliminar: limita el uso a perfiles con conocimientos de programación. La interfaz web no es un complemento estético del sistema sino una decisión de diseño central: permite que analistas de datos, gestores de proyectos o auditores de calidad operen

la plataforma sin escribir una sola línea de código, configurando métricas, interpretando resultados y tomando decisiones directamente desde el navegador.

El objetivo consiste en desarrollar una aplicación web que cubra el ciclo completo de trabajo sobre un dataset: gestión de proyectos y versiones, configuración de evaluaciones, visualización de resultados y exploración exploratoria de los datos. Las capacidades concretas que debe ofrecer son:

- **Cuadro de mando principal** con resumen de proyectos, conjuntos de datos y distribución de *Quality Gates*.
- **Página de detalle de proyecto** con pestañas diferenciadas para conjuntos de datos, configuración de métricas, historial de evaluaciones y estado del *Quality Gate*.
- **Visualización de resultados de evaluación** con indicadores de puntuación de calidad (*gauge*), pestañas por métrica y listado de *issues* detectados.
- **Exploración interactiva de datos** (EDA): histogramas, diagramas de caja, gráficos de barras, gráficos de dispersión, matrices de correlación (Pearson y Spearman) y detección visual de valores atípicos con factor IQR configurable.
- **Comparación entre versiones de un dataset**: página dedicada que muestra las diferencias en número de filas, columnas, puntuación de calidad, columnas añadidas o eliminadas e *issues* nuevos, resueltos y comunes entre dos versiones.
- **Canvas de linaje de versiones**: árbol visual interactivo que representa la genealogía completa de versiones de un dataset, permitiendo navegar por la historia de cambios.
- **Gráficos de tendencia** que muestren la evolución de la calidad a lo largo de las sucesivas evaluaciones.
- **Indicadores visuales de *Quality Gate*** con códigos de color: verde (PASSED), amarillo (WARNING) y rojo (FAILED).
- **Diseño adaptable** (*responsive*) con soporte para dispositivos de escritorio, tableta y teléfono móvil.

3.2.5 OE5. Mecanismos de identificación de problemas

Detectar que un dataset tiene un 15 % de valores nulos en una columna es útil; saber si ese porcentaje ha empeorado respecto a la semana pasada, si el problema es recurrente o si ya se corrigió una vez, es lo que permite tomar decisiones informadas. La mayoría de las herramientas de calidad de datos producen un informe por ejecución pero no conservan memoria entre ejecuciones: cada análisis es un snapshot aislado sin conexión con el anterior.

Este objetivo resuelve ese problema introduciendo tres mecanismos que, combinados, convierten la evaluación puntual en un proceso de seguimiento continuo:

1. **Sistema de *issues*.** Cada problema de calidad detectado debe registrarse como un *issue* con cuatro niveles de severidad (*critical, high, medium, low*), calculada dinámicamente en función de la distancia al umbral configurado. Cada *issue* debe incluir muestras de los datos afectados (hasta cinco filas de ejemplo), con ocultación automática de los valores de columnas marcadas como PII.
2. ***Fingerprinting* determinista.** Cada *issue* debe recibir un identificador único generado mediante SHA-256 a partir de sus atributos característicos (métrica, columna, tipo de problema), permitiendo su identificación unívoca entre ejecuciones independientes. Este mecanismo, inspirado en el sistema de rastreo de *issues* de SonarQube (SonarSource, 2024), permite clasificar automáticamente cada incidencia como *nueva, recurrente* o *corregida* respecto a la evaluación anterior.
3. ***Quality Gates*.** Umbrales mínimos configurables que determinan si un conjunto de datos es apto para su uso, con tres estados posibles: PASSED (score por encima del umbral y sin exceso de *issues* críticos ni nuevos), WARNING (score dentro del margen de advertencia configurable por encima del umbral mínimo, o número de *issues* nuevos superior al límite configurado) y FAILED (score por debajo del umbral mínimo o *issues* críticos por encima del máximo permitido). Las *Quality Gates* proporcionan una señal clara y automatizable que puede integrarse en *pipelines* de MLOPS (Kreuzberger et al., 2023) o de integración continua para bloquear el uso de conjuntos de datos de calidad insuficiente.

3.3 Objetivos transversales

Además de los objetivos funcionales descritos, el desarrollo de DATAQUAL persigue un conjunto de objetivos transversales de calidad del software que condicionan las decisiones arquitectónicas y tecnológicas del proyecto:

Seguridad

Autenticación basada en JWT con *tokens* de acceso y refresco, *hashing* de contraseñas mediante PBKDF2, limitación de tasa de peticiones (*rate limiting*), validación de entradas en los puntos críticos mediante esquemas Marshmallow, protección contra inyección de código en las reglas de consistencia lógica y enmascaramiento automático de columnas marcadas como PII.

Escalabilidad

Procesamiento asíncrono de evaluaciones mediante Celery y Redis como *broker* de mensajes, lo que permite escalar horizontalmente el número de *workers* en función de la carga de trabajo, así como separación de responsabilidades entre servicios.

Mantenibilidad

Arquitectura modular basada en *blueprints*, servicios y modelos, con un sistema de

métricas extensible por *plugins* que permite incorporar nuevas métricas con un esfuerzo mínimo. Migraciones de base de datos versionadas y separación estricta entre *frontend* y *backend*.

Usabilidad

Interfaz de usuario basada en Material Design con formularios dotados de validación en tiempo real, notificaciones *toast*, migas de pan (*breadcrumbs*) de navegación y estados de carga y error claramente diferenciados. La plataforma soporta español e inglés con cambio de idioma en tiempo real, sin necesidad de recargar la aplicación.

Portabilidad

Despliegue del *stack* completo mediante Docker Compose, con configuración por variables de entorno y sin dependencias de servicios en la nube propietarios. Los ocho servicios que componen la plataforma (*frontend*, *backend*, PostgreSQL, MinIO, Redis, Celery *worker*, Celery Beat y Flower) se orquestan conjuntamente, lo que garantiza la reproducibilidad del entorno y que los datos no salgan de la infraestructura propia.

3.4 Alcance y limitaciones

El alcance del proyecto abarca el diseño, la implementación y la validación de DATA-QUAL como plataforma *full-stack*, cubriendo los cinco objetivos específicos descritos en la sección 3.2: el módulo de ingesta con parseo robusto y versionado, el motor de evaluación con siete métricas parametrizables, la API RESTful con los módulos funcionales planificados, la aplicación web con cuadros de mando interactivos, y los mecanismos de identificación y seguimiento de problemas. El sistema se despliega íntegramente mediante Docker Compose, se valida con conjuntos de datos reales y se documenta en los anexos de la presente memoria (especificación de la API y catálogo de métricas). La pila tecnológica queda fijada por las decisiones de arquitectura adoptadas: Python con Flask y PostgreSQL en el *backend*, React con Next.js y TypeScript en el *frontend*, Celery con Redis para el procesamiento asíncrono, y alineación explícita con los estándares ISO/IEC 25012 (ISO/IEC, 2008) e ISO/IEC 5259 (ISO/IEC, 2024).

Fuera de este alcance quedan tres aspectos que, si bien son relevantes en un contexto de producción real, no forman parte del presente trabajo.

El primero es el **procesamiento de grandes volúmenes de datos**. El motor de evaluación carga el dataset completo en memoria mediante Pandas, lo que limita el tamaño práctico de los ficheros a lo que la memoria RAM disponible permita procesar sin degradación. La evaluación distribuida sobre datasets masivos mediante Apache Spark o Dask requiere una arquitectura diferente y queda como línea de trabajo futuro.

El segundo es la **corrección automática de datos**. La plataforma diagnostica y clasifica los problemas de calidad, pero la decisión y ejecución de las acciones correctoras (limpie-

za, imputación, deduplicación) corresponde al usuario. Incorporar sugerencias de corrección automatizadas es una de las líneas de trabajo futuro identificadas en el capítulo ??.

El tercero es la **integración directa con fuentes de datos externas**. La arquitectura de almacenamiento basada en MinIO es compatible con el protocolo S3, pero no se desarrollan conectores específicos para bases de datos (MySQL, BigQuery, Snowflake) ni para servicios de almacenamiento en la nube (AWS S3, Azure Blob, Google Cloud Storage). El usuario interactúa con la plataforma a través de ficheros CSV cargados manualmente.

ANEXOS

Referencias

- Alteryx, Inc. (2024). Alteryx: Data analytics and process automation platform. <https://www.alteryx.com/>. Consultado: marzo 2026.
- Anaconda, Inc. (2022). State of data science 2022.
- Bayer, M. (2024). SQLAlchemy: The database toolkit for Python. <https://www.sqlalchemy.org/>.
- Buolamwini, J. and Gebru, T. (2018). Gender shades: Intersectional accuracy disparities in commercial gender classification. In *Proceedings of the 1st Conference on Fairness, Accountability and Transparency*, volume 81 of *Proceedings of Machine Learning Research*, pages 77–91. PMLR.
- Celery Project (2024). Celery: Distributed task queue. <https://docs.celeryq.dev/>.
- Chart.js Contributors (2024). Chart.js: Simple yet flexible JavaScript charting for designers & developers. <https://www.chartjs.org/>.
- CrowdFlower (2016). 2016 data science report.
- DAMA International (2017). *DAMA-DMBOK: Data Management Body of Knowledge*. Technics Publications, 2 edition.
- Dastin, J. (2018). Amazon scraps secret AI recruiting tool that showed bias against women. Reuters. Consultado: 2026.
- Docker, Inc. (2024). Docker: Accelerated container application development. <https://www.docker.com/>.
- DQOps (2024). DQOps — data quality operations center. <https://dqops.com/>. Consultado: marzo 2026.
- Evidently AI (2024). Evidently: Open-source ML monitoring and data quality framework. <https://www.evidentlyai.com/>. Consultado: marzo 2026.
- Fielding, R. T. (2000). *Architectural Styles and the Design of Network-based Software Architectures*. PhD thesis, University of California, Irvine. Capítulo 5: Representational State Transfer (REST).
- Gamma, E., Helm, R., Johnson, R., and Vlissides, J. (1994). *Design Patterns: Elements of Reusable Object-Oriented Software*. Addison-Wesley.

- Great Expectations (2024). Great expectations: Always know what to expect from your data. <https://greatexpectations.io/>. Consultado: marzo 2026.
- ISO/IEC (2008). ISO/IEC 25012:2008 — software engineering — software product quality requirements and evaluation (SQuaRE) — data quality model. Standard, International Organization for Standardization.
- ISO/IEC (2015). ISO/IEC 25024:2015 — systems and software engineering — systems and software quality requirements and evaluation (SQuaRE) — measurement of data quality. Standard, International Organization for Standardization.
- ISO/IEC (2024). ISO/IEC 5259 — data quality for analytics and machine learning (ML). Standard, International Organization for Standardization. Partes 1 a 5 publicadas en 2024.
- Kaggle (2022). State of data science and machine learning 2022. <https://www.kaggle.com/kaggle-survey-2022>. Consultado: 2026.
- Kreuzberger, D., Kühl, N., and Hirschl, S. (2023). Machine learning operations (MLOps): Overview, definition, and architecture. *IEEE Access*, 11:31866–31879.
- Meta Platforms, Inc. (2024). React: A javascript library for building user interfaces. <https://react.dev/>.
- Microsoft (2024). TypeScript: Javascript with syntax for types. <https://www.typescriptlang.org/>.
- MinIO, Inc. (2024). MinIO: High performance object storage. <https://min.io/>.
- MUI (2024). Material UI: React components for faster and easier web development. <https://mui.com/>.
- Ng, A. (2021). A chat with Andrew on MLOps: From model-centric to data-centric AI. DeepLearning.AI, <https://www.youtube.com/watch?v=06-AZXmwHjo>. Consultado: 2026.
- Parlamento Europeo y Consejo de la Unión Europea (2016). Reglamento (UE) 2016/679 del parlamento europeo y del consejo relativo a la protección de las personas físicas en lo que respecta al tratamiento de datos personales (Reglamento General de Protección de Datos). Diario Oficial de la Unión Europea, L 119, pp. 1–88.
- Parlamento Europeo y Consejo de la Unión Europea (2024). Reglamento (UE) 2024/1689 del parlamento europeo y del consejo por el que se establecen normas armonizadas en materia de inteligencia artificial (Reglamento de Inteligencia Artificial). Diario Oficial de la Unión Europea.
- Qlik Technologies, Inc. (2024). Talend: Data integration and integrity platform. <https://www.talend.com/>. Consultado: marzo 2026.
- Redis Ltd. (2024). Redis: In-memory data structure store. <https://redis.io/>.
- Redman, T. C. (1998). The impact of poor data quality on the typical enterprise. *Communications of the ACM*, 41(2):79–82.

- Redman, T. C. (2001). *Data Quality: The Field Guide*. Digital Press.
- Ronacher, A. (2024). Flask: A python microframework. <https://flask.palletsprojects.com/>.
- Sambasivan, N., Kapania, S., Highfill, H., Akrong, D., Paritosh, P., and Aroyo, L. M. (2021). “everyone wants to do the model work, not the data work”: Data cascades in high-stakes AI. In *Proceedings of the 2021 CHI Conference on Human Factors in Computing Systems*. ACM.
- Schelter, S., Lange, D., Schmidt, P., Celikel, M., Biessmann, F., and Grafberger, A. (2018). Automating large-scale data quality verification. In *Proceedings of the VLDB Endowment*, volume 11, pages 1781–1794. Apache Deequ.
- Soda Data, Inc. (2024). Soda core: Open-source data quality framework. <https://github.com/sodadata/soda-core>. Consultado: marzo 2026.
- SonarSource (2024). SonarQube: Code quality and security. <https://www.sonarsource.com/products/sonarqube/>.
- The PostgreSQL Global Development Group (2024). PostgreSQL: The world’s most advanced open source relational database. <https://www.postgresql.org/>.
- Tukey, J. W. (1977). *Exploratory Data Analysis*. Addison-Wesley.
- Union.ai and Pandera Contributors (2024). Pandera: A statistical data testing toolkit for Python. <https://pandera.readthedocs.io/>. Consultado: marzo 2026.
- Vercel (2024). Next.js: The react framework for the web. <https://nextjs.org/>.
- Wang, R. Y. and Strong, D. M. (1996). Beyond accuracy: What data quality means to data consumers. *Journal of Management Information Systems*, 12(4):5–33.
- ydata-ai (2024). ydata-profiling: Extended pandas profiling. <https://github.com/ydataai/ydata-profiling>. Consultado: marzo 2026.

Este documento fue editado y tipografiado con $\text{\LaTeX}$
empleando la clase **gita-tfg** que se puede encontrar en:

<https://github.com/anarubioruiz/gita-tfg>

La clase **gita-tfg** está basada en la clase **esi-tfg**:

<https://github.com/UCLM-ESI/esi-tfg>